

Estimation non paramétrique de processus de Hawkes et application à la microstructure des échanges décentralisés

Adrien Damez, Ilyas El-Tabouti, Majd Sebbah, Housseem Elhamdi, Abdellah Taybi

4 juin 2026

Table des matières

1	Introduction	2
2	Modèle d'estimation non paramétrique	3
2.1	Statistiques d'un processus de Hawkes et équation de Wiener–Hopf	3
2.2	Estimation non paramétrique	4
2.2.1	Méthode Neural Hawkes	4
2.2.2	Choix numériques	6
2.3	Modèle discret de Kirchner	7
3	Validation sur données simulées	7
3.1	Processus non marqué	8
3.2	Processus marqué	8
3.3	Évaluation et convergence	10
3.4	Comparaison avec le modèle discret de Kirchner	11
4	Application aux données DeFi	13
4.1	Présentation des données	13
4.2	Adaptation du modèle aux données blockchain	14
4.3	Estimation des noyaux	14
4.3.1	Interactions entre achats et ventes	14
4.3.2	Interactions entre swaps, mint et burn	17
5	Conclusion	17

Résumé

Les processus de Hawkes constituent un cadre classique pour modéliser les dépendances temporelles entre événements financiers. Dans ce travail, nous étudions l'estimation non paramétrique de processus de Hawkes multivariés marqués à l'aide de l'approche Neural Hawkes proposée par Fabre et Muni Toke (2025). Les noyaux d'excitation sont estimés à partir des statistiques d'ordre deux du processus en résolvant l'équation de Wiener–Hopf à l'aide d'un réseau de neurones de type Deep Galerkin Method. Après une validation sur données simulées, la méthode est appliquée à plusieurs pools Uniswap V3 sur Ethereum afin d'étudier la microstructure des marchés décentralisés. Contrairement aux marchés centralisés traditionnellement étudiés dans la littérature, les échanges décentralisés reposent sur une architecture blockchain dans laquelle les transactions sont regroupées par blocs et les mécanismes de liquidité diffèrent de ceux des carnets d'ordres. Les résultats obtenus mettent en évidence des dépendances temporelles entre événements ainsi qu'une influence significative de la taille des transactions. Nous comparons également cette approche continue à un modèle discret de type INAR proposé par Kirchner (2016), plus directement adapté à la structure des données blockchain. Ce rapport illustre à la fois le potentiel et les limites des processus de Hawkes pour l'analyse de la microstructure des marchés décentralisés.

MOTS-CLÉS : processus de Hawkes, estimation non paramétrique, Neural Hawkes, marchés de cryptomonnaies, microstructure, Uniswap.

1. Introduction

Les échanges sur les marchés financiers peuvent être vus comme une succession d'événements discrets : transactions, ajouts ou retraits de liquidité, modifications du carnet d'ordres, etc. L'objectif est alors de modéliser non pas directement l'évolution du prix, mais les instants auxquels ces événements surviennent.

Les processus ponctuels constituent un cadre naturel pour décrire ce type de données. Pour un processus ponctuel $N(t)$, la quantité fondamentale est l'intensité conditionnelle

$$\lambda(t) = \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \mathbb{E}[N(t + \Delta t) - N(t) \mid \mathcal{F}_t],$$

où $\mathcal{F}_t$ désigne l'information disponible jusqu'au temps t .

L'intensité peut être interprétée comme un taux instantané d'arrivée des événements. En particulier, pour un intervalle de temps infinitésimal dt ,

$$\mathbb{E}[dN(t) \mid \mathcal{F}_t] = \lambda(t)dt.$$

Une intensité élevée indique donc qu'un nouvel événement est susceptible d'apparaître dans un futur proche.

Les processus de Hawkes correspondent à une classe particulière de processus ponctuels dans laquelle l'intensité dépend des événements passés. Chaque événement observé peut ainsi modifier temporairement la probabilité d'apparition des événements futurs. Dans le cas multivarié marqué considéré dans ce travail, l'intensité d'un événement de type i s'écrit

$$\lambda_i(t) = \mu_i + \sum_{j=1}^D \sum_{t_k^j < t} \phi_{ij}(t - t_k^j, m_k^j),$$

où μ_i représente une intensité de base, t_k^j et m_k^j désignent respectivement la date et la marque du k -ième événement de type j , et ϕ_{ij} mesure l'influence exercée par cet événement sur l'intensité future. Les marques permettent d'incorporer des informations supplémentaires telles que la direction d'une transaction, son volume, son type...

Grâce à cette structure, les processus de Hawkes sont largement utilisés en microstructure des marchés pour quantifier les mécanismes d'auto-excitation et les interactions entre différents types d'événements. L'interprétation directe des noyaux ϕ_{ij} permet notamment d'étudier des relations causales et de caractériser les dépendances temporelles présentes dans les données.

L'estimation de ces noyaux constitue cependant un problème difficile. Les approches paramétriques reposent sur le choix a priori d'une famille de noyaux, ce qui peut limiter leur capacité à reproduire la structure réelle des données. Les méthodes non paramétriques cherchent au contraire à reconstruire directement les noyaux à partir des observations. Parmi elles, la méthode de Wiener–Hopf de BACRY et MUZY (2016) exploite une caractérisation des processus de Hawkes par leurs statistiques d'ordre deux. Plus récemment, FABRE et MUNI TOKE (2025) ont proposé une approche reposant sur des réseaux de neurones, permettant de résoudre cette équation d'estimation dans des contextes de grande dimension.

Dans ce travail, nous étudions cette méthode d'estimation non paramétrique et son application à des données issues du protocole Uniswap V3. Après avoir présenté le cadre théorique et la procédure d'estimation, nous validons la méthode sur des données simulées avant d'analyser les dépendances temporelles observées sur plusieurs pools de liquidité.

2. Modèle d'estimation non paramétrique

2.1. Statistiques d'un processus de Hawkes et équation de Wiener–Hopf

On considère un processus de Hawkes marqué multivarié de dimension D . Chaque événement est caractérisé par sa date d'occurrence ainsi que par une marque décrivant certaines de ses propriétés, par exemple sa direction, son volume ou son type. Les interactions entre événements sont décrites par les noyaux ϕ_{ij} , qui quantifient l'influence d'un événement passé de type j sur l'intensité future des événements de type i .

Une quantité fondamentale associée à un noyau est sa norme

$$\|\phi_{ij}\| = \sum_{x=1}^M p_j(x) \int_0^{+\infty} \phi_{ij}(t, x) dt.$$

où p_j désigne la distribution des marques du processus j . Cette quantité mesure l'effet total produit par un événement de type j sur les événements futurs de type i .

En regroupant les noyaux dans la matrice

$$\Phi = (\phi_{ij})_{1 \leq i, j \leq D},$$

on définit la matrice des normes

$$\|\Phi\| = (\|\phi_{ij}\|)_{1 \leq i, j \leq D}.$$

et le branching ratio

$$R = \rho(\|\Phi\|),$$

où ρ désigne le rayon spectral de la matrice. Le branching ratio possède une interprétation simple : il correspond au nombre moyen d'événements directement engendrés par un événement donné. Lorsque $R < 1$, chaque événement produit en moyenne moins d'un descendant et l'activité du système reste bornée. À l'inverse, si $R > 1$, le nombre d'événements croît de manière explosive, ce qui empêche l'existence d'un régime stationnaire, le processus de Hawkes est instable.

Sous l'hypothèse de stationnarité, l'intensité moyenne du processus est donnée par

$$\Lambda = (I - \|\Phi\|)^{-1} \mu,$$

où μ désigne le vecteur des intensités exogènes et I la matrice identité. Cette relation montre que l'intensité observée résulte à la fois d'une activité exogène et d'une activité endogène créée par les mécanismes d'auto-excitation du processus.

L'estimation des noyaux repose sur les statistiques d'ordre deux du processus. Pour un événement de type j observé à l'instant 0, on définit

$$G_{ij}(t, x) = \mathbb{E} [dN_i(t) \mid dN_j(0) = 1, m_j = m] - \Lambda_i dt.$$

La quantité G_{ij} mesure ainsi l'excès d'activité observé après un événement de référence relativement à l'activité moyenne du processus. Une valeur positive de G_{ij} traduit un phénomène d'excitation, tandis qu'une valeur négative correspond à un effet inhibiteur.

Le résultat central de BACRY et MUZY (2016) montre que les noyaux d'un processus de Hawkes stationnaire sont entièrement caractérisés par ces statistiques d'ordre deux. Plus précisément, les noyaux vérifient une équation intégrale de Fredholm de seconde espèce, également appelée équation de Wiener–Hopf :

$$G = \Phi + \Phi * H,$$

où H est une fonction construite à partir des statistiques d'ordre deux.

Cette relation est particulièrement importante puisqu'elle ramène le problème d'estimation des noyaux à la résolution d'une équation intégrale. La méthode de Wiener–Hopf consiste alors à discrétiser cette équation afin de reconstruire numériquement les noyaux. Cependant, cette approche devient rapidement coûteuse lorsque le nombre de dimensions ou de marques augmente. C'est cette difficulté qui motive l'approche Neural Hawkes présentée dans la section suivante.

2.2. Estimation non paramétrique

2.2.1. Méthode Neural Hawkes

L'approche Neural Hawkes proposée par FABRE et MUNI TOKE (2025) consiste à remplacer la résolution matricielle de l'équation de Wiener–Hopf par un problème d'apprentissage. Plutôt que d'estimer les noyaux sur une grille discrète, ceux-ci sont représentés par une famille de fonctions paramétrées par les poids d'un réseau de neurones.

Dans notre implémentation, chaque ligne de la matrice des noyaux est estimée indépendamment. Pour un processus cible i fixé, le réseau prend en entrée le temps écoulé depuis l'événement déclencheur ainsi que sa marque,

$$(t, x),$$

et retourne simultanément les estimations

$$(\phi_{i1,\theta}(t,x), \dots, \phi_{iD,\theta}(t,x)).$$

Cette procédure est répétée pour chaque ligne de la matrice afin de reconstruire l'ensemble des noyaux du processus. La notation θ correspond à l'ensemble des paramètres du réseau de neurones et ϕ_θ les noyaux ainsi estimés.

Comme dans l'article FABRE et MUNI TOKE (2025), nous utilisons une architecture de type Deep Galerkin Method (DGM) (cf. figure 1). Cette architecture repose sur une succession de cellules comportant des mécanismes de portes inspirés des réseaux récurrents et permet de représenter efficacement des fonctions définies sur un domaine continu. L'ensemble des noyaux estimés par le




FIGURE 1. Architecture type Deep Galerkin Method (DGM).

réseau est noté

$$\phi_\theta = (\phi_{ij,\theta})_{1 \leq i,j \leq D}.$$

L'approximation des noyaux induit naturellement une approximation des statistiques d'ordre deux au travers de l'équation de Wiener-Hopf,

$$G_\theta = \phi_\theta + \mathcal{I}(\phi_\theta),$$

où $\mathcal{I}$ désigne l'opérateur intégral apparaissant dans l'équation de Wiener-Hopf. Les paramètres du réseau sont alors ajustés de manière à minimiser l'écart entre les statistiques observées G et leur reconstruction G_θ .

La fonction de perte utilisée est donnée par

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{k=1}^N w_k |G(t_k, m_k) - G_\theta(t_k, m_k)|^2,$$

où les points de collocation (t_k, m_k) sont échantillonnés aléatoirement dans le domaine d'étude.

Comme dans FABRE et MUNI TOKE (2025), une pondération temporelle des résidus est utilisée. Celle-ci favorise un apprentissage progressif de la structure causale du noyau en temps et améliore la précision de l’estimation aux faibles horizons temporels. Les intégrales intervenant dans l’opérateur $\mathcal{I}$ sont évaluées numériquement par quadrature à chaque étape de l’entraînement.

Cette approche fournit directement une approximation continue des noyaux tout en évitant la construction et l’inversion du système linéaire associé à la méthode de Wiener–Hopf classique.

2.2.2. Choix numériques

Les statistiques d’ordre deux sont estimées directement à partir des données observées. Pour chaque événement de référence de type j et de marque m , nous calculons le taux moyen d’apparition des événements de type i dans des fenêtres temporelles successives. Cet estimateur est ensuite recentré par l’intensité moyenne Λ_i , conformément à la définition de la fonction G .

L’estimation des noyaux est réalisée sur un horizon temporel fini T_{kernel} . Plutôt que de fixer cette quantité arbitrairement, nous l’estimons à partir des données. Pour chaque processus, nous calculons les temps inter-arrivées successifs puis retenons leur quantile d’ordre 95%. L’horizon utilisé correspond ensuite au maximum de ces quantiles parmi l’ensemble des processus. Cette procédure permet d’adapter automatiquement l’échelle temporelle d’estimation aux données observées tout en limitant l’influence des temps exceptionnellement longs, pour lesquels les statistiques deviennent plus bruitées.

Contrairement à l’article original, les statistiques G sont estimées sur une grille temporelle uniforme. Ce choix simplifie l’estimation des moments d’ordre deux et s’est révélé suffisant dans les expériences réalisées. En revanche, l’évaluation de l’opérateur intégral de Wiener–Hopf est effectuée à l’aide d’une quadrature logarithmique. Cette discrétisation permet d’obtenir une meilleure résolution aux petites échelles temporelles, où les noyaux présentent généralement les variations les plus marquées. L’architecture retenue comporte une cellule DGM de dimension cachée 64 suivie d’une couche de sortie linéaire. Les paramètres sont optimisés à l’aide de l’algorithme Adam avec un taux d’apprentissage de 10^{-3} . À chaque époque, 1024 points de collocation sont échantillonnés aléatoirement et utilisés pour l’entraînement avec une taille de mini-batch de 8.

L’entraînement est interrompu automatiquement lorsque la perte ne présente plus d’amélioration significative. Plus précisément, l’optimisation est arrêtée lorsque la perte moyenne sur les 100 dernières itérations n’a pas diminué d’au moins 1%. Dans les expériences réalisées, ce critère conduit généralement à des durées d’entraînement comprises entre 500 et 1000 époques.

Comme dans l’article de FABRE et MUNI TOKE (2025), les variables d’entrée sont normalisées avant leur passage dans le réseau afin d’améliorer la stabilité de l’optimisation. Les points de collocation sont rééchantillonnés à chaque itération, ce qui permet d’explorer progressivement l’ensemble du domaine temporel considéré.

Enfin, contrairement à certaines implémentations de processus de Hawkes, aucune contrainte de positivité n’est imposée aux noyaux estimés. Le réseau est ainsi autorisé à représenter aussi bien des effets excitateurs que des effets inhibiteurs. Par ailleurs, l’article original recommande l’utilisation de la variable transformée $\log(t)$ en entrée du réseau afin d’améliorer la résolution aux petites échelles temporelles. Plusieurs essais ont été réalisés dans ce cadre sans amélioration notable des résultats obtenus. Nous avons donc conservé la variable temporelle brute t .

2.3. Modèle discret de Kirchner

Les événements observés sur Ethereum sont regroupés au sein de blocs validés à intervalles réguliers. Une approche alternative aux processus de Hawkes continus et peut-être plus naturelle consisterait à modéliser directement les comptages d'événements observés dans chaque bloc. Cette idée conduit aux modèles autorégressifs entiers proposés notamment par KIRCHNER (2016), qui peuvent être vus comme un analogue discret des processus de Hawkes.

Pour un pas de temps Δ , on note $N_t \in \mathbb{N}^D$ le vecteur contenant le nombre d'événements observés dans le bloc t . Le modèle s'écrit alors

$$\lambda_t = \mu + \sum_{k=1}^K A_k N_{t-k},$$

où λ_t représente l'intensité conditionnelle du processus discret, μ un vecteur d'intensités de base et A_k les matrices décrivant l'influence des événements observés k blocs auparavant. Les matrices A_k jouent ainsi un rôle analogue aux noyaux d'un processus de Hawkes continu.

Un résultat important montre que lorsque le pas de discrétisation Δ tend vers zéro, le modèle discret converge vers un processus de Hawkes continu convenablement paramétré. Les coefficients A_k peuvent alors être interprétés comme une approximation discrète du noyau intégré sur chaque intervalle temporel. Cette propriété fournit un lien théorique entre les deux approches.

Le modèle de Kirchner présente plusieurs avantages dans notre contexte. Il s'adapte naturellement à la structure des données blockchain, ne nécessite aucune reconstruction temporelle à l'intérieur des blocs et son estimation repose sur des techniques de régression relativement simples. En revanche, contrairement au modèle présenté dans les sections précédentes, il ne permet pas d'incorporer directement des marques associées aux événements. L'information portée par le volume des transactions est donc perdue dans cette représentation.

3. Validation sur données simulées

Avant d'appliquer la méthode à des données réelles, il est nécessaire de vérifier sa capacité à reconstruire des noyaux connus. Nous considérons pour cela deux processus simulés. Le premier est un processus de Hawkes non marqué de dimension $D = 3$, conçu pour illustrer différentes formes de noyaux (exponentiels, noyaux retardés et interactions nulles). Le second est un processus marqué de dimension $D = 2$ comportant cinq marques, dont l'objectif est d'évaluer la capacité de la méthode à distinguer l'influence temporelle des événements de l'effet associé aux marques.

Les données synthétiques sont générées à partir de la représentation en clusters de HAWKES et OAKES (1974). Dans cette construction, les événements exogènes (immigrants) sont simulés selon des processus de Poisson homogènes, puis chaque événement engendre récursivement des descendants dont le nombre suit une loi de Poisson et dont les temps d'occurrence sont distribués selon les noyaux d'excitation.

Pour chacune des deux expériences, les paramètres de simulation sont choisis de manière à générer environ 2×10^6 événements. Les noyaux estimés sont ensuite comparés aux noyaux ayant servi à la génération des données.

3.1. Processus non marqué

Nous considérons tout d’abord un processus de Hawkes non marqué de dimension $D = 3$. Les noyaux utilisés pour la simulation ont été choisis de manière à représenter différentes formes d’interactions : noyaux exponentiels, effets retardés, noyaux à support étendu ainsi que certaines interactions nulles. La figure 2 compare les noyaux estimés aux noyaux ayant servi à la génération des données. Les principales structures temporelles sont correctement retrouvées. Les noyaux exponentiels sont bien reproduits, ainsi que ceux présentant des excitations retardées. Les interactions nulles restent quant à elles proches de zéro, bien que les erreurs relatives les plus importantes soient observées sur ces noyaux de très faible amplitude.

Ces résultats montrent que l’approche Neural Hawkes est capable de reconstruire des noyaux de formes variées à partir des seules statistiques d’ordre deux du processus.




FIGURE 2. Comparaison entre les noyaux réels et les noyaux estimés pour le processus de Hawkes non marqué simulé.

3.2. Processus marqué

Nous considérons ensuite un processus de Hawkes marqué de dimension $D = 2$ comportant cinq marques. Les noyaux simulés sont construits sous une forme séparable

$$\phi_{ij}(t, x) = \psi_{ij}(t) h_{ij}(x),$$

où ψ_{ij} décrit la dépendance temporelle et h_{ij} l’effet de la marque. Tous les noyaux partagent ainsi une même structure temporelle exponentielle, tandis que leur amplitude dépend de la catégorie de marque considérée.

La figure 3 représente les statistiques d'ordre deux empiriques $G_{ij}(t, x)$ obtenues pour les différentes marques. Comme attendu, leur amplitude augmente avec la marque considérée, reflétant le rôle croissant des événements de grande taille dans les mécanismes d'excitation du processus.

L'estimation fournit directement les noyaux marqués $\phi_{ij}(t, x)$. Afin d'en faciliter l'interprétation, nous considérons le noyau agrégé

$$\varphi_{ij}(t) = \sum_{x=1}^M p_j(x) \phi_{ij}(t, x),$$

ainsi que la fonction de marque

$$f_{ij}(x) = \frac{1}{\|\phi_{ij}\|} \int_0^{T_{\text{kernel}}} \phi_{ij}(t, x) dt.$$

Dans le cas particulier de cette expérience, les noyaux simulés sont séparables. Les quantités agrégées définies ci-dessus coïncident alors avec les fonctions ψ_{ij} et h_{ij} utilisées pour générer les données.

La figure 4 compare les quantités estimées aux fonctions ayant servi à la simulation. La décroissance temporelle des noyaux agrégés est correctement retrouvée, tout comme la hiérarchie entre les différentes marques. Ces résultats montrent que la méthode parvient à reconstruire à la fois la dynamique temporelle des interactions et la dépendance aux marques.




FIGURE 3. Statistiques d'ordre deux estimées $G^{ij}(t, x)$ du processus de Hawkes marqué simulé pour les différentes valeurs de marque.

Afin de quantifier la qualité de reconstruction, nous considérons trois indicateurs complémentaires : l'erreur relative moyenne en norme L^2 sur les noyaux, l'erreur relative sur la matrice de branching

$$\|\phi_{ij}\| = \int_0^{T_{\text{kernel}}} \varphi_{ij}(t) dt,$$

et l'erreur relative sur son rayon spectral $\rho(\|\Phi\|)$.

TABLE 1. Qualité de reconstruction sur les données simulées.

Expérience	Erreur L^2 moyenne	Erreur moyenne sur les normes	Erreur sur $\rho(\ \Phi\)$
Non marqué ($D = 3$)	11.7%	4.6%	2.7%
Marqué ($D = 2, M = 5$)	2.7%	1.3%	0.1%

Les résultats sont reportés dans le Tableau 1. Les erreurs relatives sur les noyaux peuvent être fortement amplifiées lorsque certaines interactions sont de très faible amplitude, voire nulles. Les




FIGURE 4. Comparaison entre les noyaux réels et les noyaux estimés pour le processus de Hawkes marqué simulé. Les deux premières colonnes représentent les noyaux temporels agrégés $\phi^{ij}(t)$, tandis que les deux dernières colonnes représentent les fonctions de marque agrégées $f^{ij}(x)$. La méthode restitue correctement à la fois la dynamique temporelle des noyaux et la dépendance aux marques.

métriques fondées sur la matrice de branching et son rayon spectral fournissent ainsi une mesure plus robuste de la qualité globale de reconstruction.

3.3. Évaluation et convergence

Afin d'évaluer quantitativement les performances de la méthode, nous nous plaçons dans le cas d'un processus de Hawkes non marqué de dimension $D = 2$. Les noyaux estimés sont comparés aux noyaux exponentiels ayant servi à la simulation des données à l'aide d'une erreur quadratique moyenne normalisée de type L^2 .

Soient ϕ_{ij} les noyaux réels et $\widehat{\phi}_{ij}^N$ les noyaux estimés à partir d'un échantillon de taille N . En discrétisant l'intervalle temporel $[0, T]$ sur une grille de $K + 1$ points, nous considérons la métrique suivante :

$$\varepsilon_2(N) = \sqrt{\frac{1}{D^2(K+1)} \sum_{i,j=1}^D \sum_{k=0}^K \left(\widehat{\phi}_{ij}^N\left(\frac{kT}{K}\right) - \phi_{ij}\left(\frac{kT}{K}\right) \right)^2}.$$

Afin d'obtenir une mesure relative indépendante de l'amplitude des noyaux, nous utilisons ensuite la version normalisée

$$\bar{\varepsilon}_2(N) = \frac{\varepsilon_2(N)}{\sup_{i,j} \|\phi_{ij}\|_\infty}.$$

Pour étudier la convergence empirique de la méthode, la base de données simulée est divisée

en plusieurs sous-échantillons contenant un nombre croissant d'événements. Le modèle est alors réentraîné pour chaque taille d'échantillon, puis l'erreur normalisée $\bar{\varepsilon}_2(N)$ est recalculée.




FIGURE 5. Convergence empirique de l'erreur normalisée en fonction de la taille de l'échantillon pour un processus de Hawkes non marqué de dimension $D = 2$ à noyaux exponentiels. La droite pointillée correspond à une régression linéaire en échelle log-log.

La figure 5 montre l'évolution de l'erreur normalisée en fonction du nombre d'événements N . On observe une décroissance globale de l'erreur lorsque la taille de l'échantillon augmente, ce qui traduit la convergence empirique de la méthode. Les légères fluctuations observées pour certaines tailles d'échantillon proviennent de la variabilité statistique inhérente aux données simulées ainsi que du caractère non convexe de l'optimisation neuronale.

La droite en pointillés correspond à une régression linéaire réalisée en échelle log-log. La pente obtenue est d'environ -0.33 , ce qui correspond à une décroissance de l'erreur en $N^{-0.33}$. Cette valeur doit être interprétée comme un résultat empirique propre à cette expérience et non comme un taux théorique de convergence. Elle reste néanmoins cohérente avec une convergence de type loi de puissance généralement observée pour les méthodes non paramétriques d'estimation des processus de Hawkes.

3.4. Comparaison avec le modèle discret de Kirchner

Comme expliqué dans la Section 2.3, les données Ethereum sont observées sous forme de blocs. L'application du modèle Neural Hawkes nécessite donc une étape de reconstruction temporelle consistant à répartir uniformément les événements à l'intérieur de chaque bloc tout en conservant leur ordre d'apparition.

Afin d'évaluer l'impact de cette reconstruction, nous reprenons les données simulées de la partie 3.2 en limitant la taille de l'échantillon afin d'obtenir un nombre d'événements comparable à celui observé sur les données blockchain, soit environ 230 000 événements. Les temps d'arrivée sont ensuite agrégés en blocs de manière à reproduire des caractéristiques proches de celles observées sur les données réelles, environ 50% de blocs sans événement et 0.8 événement par bloc en moyenne.

Nous comparons alors deux approches :

- l'estimation directe du modèle discret de Kirchner à partir des comptages par bloc ;
- la reconstruction de temps d'arrivée continus suivie de l'estimation Neural Hawkes.

Cette expérience permet de comparer les estimations obtenues aux noyaux théoriques utilisés pour la simulation et d'évaluer la perte d'information induite par l'agrégation en blocs.




FIGURE 6. Comparaison entre les noyaux intégrés théoriques agrégés sur les marques (bleu), les noyaux agrégés obtenus par la méthode Neural Hawkes après reconstruction temporelle (pointillés noirs) et les estimations du modèle discret de Kirchner (violet). Les données proviennent du processus simulé de la sous-section 3.2, après troncature et agrégation en blocs. Le modèle de Kirchner ne prenant pas en compte les marques, la comparaison est effectuée sur les noyaux agrégés.

La Figure 6 compare les noyaux estimés par les deux méthodes aux noyaux théoriques. Dans les deux cas, les principales structures temporelles sont correctement retrouvées malgré l’agrégation en blocs.

Ces résultats suggèrent que la redistribution uniforme des événements à l’intérieur des blocs préserve l’essentiel des dépendances temporelles. Ils apportent ainsi un soutien empirique au prétraitement retenu pour les données Ethereum.

La comparaison avec les estimations obtenues sur données réelles (Figure 9) conduit à des conclusions similaires. Les deux approches mettent en évidence une forte auto-excitation des flux d’achats et de ventes, tandis que les interactions croisées apparaissent plus sensibles au choix du modèle. Les principales dépendances directionnelles semblent néanmoins préservées.

4. Application aux données DeFi

Les résultats obtenus sur données simulées montrent que la méthode est capable de reconstruire avec précision les noyaux d'un processus de Hawkes marqué dans un cadre contrôlé. Nous appliquons désormais cette approche à des données réelles issues de marchés décentralisés afin d'étudier les dépendances temporelles entre les différents types d'événements observés sur la blockchain.

4.1. Présentation des données

Les données étudiées proviennent de plusieurs pools Uniswap V3 déployées sur Ethereum Mainnet. Contrairement aux marchés centralisés reposant sur un carnet d'ordres, Uniswap utilise un mécanisme d'*Automated Market Maker* (AMM) dans lequel les utilisateurs échangent directement contre les réserves de liquidité d'un pool.

Bien que les pools Uniswap V3 reposent sur un mécanisme de liquidité concentrée, leur fonctionnement peut être interprété localement comme celui d'un AMM à produit constant, dans lequel les réserves x et y évoluent de manière à préserver l'invariant

$$xy = k.$$

Les transactions modifient ainsi directement les réserves du pool et, par conséquent, le prix d'échange observé (DI NOSSE et al. 2025).

Chaque pool génère différents types d'événements enregistrés sur la blockchain. Dans ce travail, nous considérons principalement les événements :

- **swap**, correspondant à un échange entre les deux actifs du pool ;
- **mint**, correspondant à un ajout de liquidité ;
- **burn**, correspondant à un retrait de liquidité.

L'échantillon étudié couvre la période du 18 janvier au 16 février 2026. Les principales caractéristiques des pools retenues sont résumées dans le tableau 2.

TABLE 2. Pools Uniswap V3 analysés

Pool	Fee	Swaps	Mint	Burn	Transactions sandwich (%)	Adresse
USDC/WETH	0.05%	230 249	4 634	4 253	1.05%	0x88e6...5640
USDC/WETH	0.30%	27 757	1 049	1 807	0.06%	0x8ad5...e6d8
WBTC/WETH	0.05%	151 283	1 038	1 303	1.92%	0x11b8...97f6
WBTC/WETH	0.30%	13 569	972	1 046	0.10%	0xcbcd...62ed
USDC/USDT	0.01%	45 334	1 484	1 627	5.51%	0x3416...27c6

Les pools à faibles frais concentrent une activité significativement plus importante que leurs équivalents à 0.30%. La pool USDC/WETH 0.05% est la plus liquide de l'échantillon avec plus de 230 000 swaps observés sur la période étudiée.

Ces pools sont également exposées à différentes formes de *Maximal Extractable Value* (MEV), c'est-à-dire à des stratégies visant à extraire un profit en exploitant l'ordre d'inclusion des transactions dans les blocs. Parmi les formes les plus courantes figurent les attaques de type *sandwich*, dans lesquelles une transaction est encadrée par deux transactions opportunistes d'un même acteur (DI NOSSE et al. 2025).

Nous avons identifié ces attaques selon la méthodologie proposée par Di Nosse et al. (2025). Les proportions observées sont inférieures à celles rapportées dans leur étude. En revanche, comme dans Di Nosse et al. (2025), les pools à faibles frais présentent une proportion plus élevée de transactions sandwich que les pools à frais plus importants. Dans la suite, ces transactions sont conservées, leur retrait n’ayant pas d’impact significatif sur les estimations obtenues.

4.2. Adaptation du modèle aux données blockchain

L’application d’un modèle de Hawkes aux données blockchain soulève cependant plusieurs difficultés absentes des données financières classiques. Les événements ne sont en effet pas observés de manière continue mais regroupés au sein de blocs Ethereum, validés toutes les douze secondes. Plusieurs transactions peuvent ainsi partager exactement le même timestamp.

Cette structure est incompatible avec l’hypothèse d’un processus ponctuel simple, sur laquelle repose la formulation continue du modèle de Hawkes. Afin de reconstruire une temporalité exploitable, nous répartissons uniformément les transactions à l’intérieur de chaque bloc tout en conservant leur ordre d’apparition. Cette procédure permet d’éliminer les simultanés artificielles introduites par l’agrégation au niveau des blocs tout en préservant l’information séquentielle disponible.

Nous ajoutons ensuite au processus une variable de marque représentant le volume de la transaction exprimé en dollars. Comme le montre la Figure 7, la distribution empirique des volumes est très asymétrique et s’étend sur plusieurs ordres de grandeur. Nous adoptons donc une discrétisation logarithmique en cinq classes de volume (*tiny*, *small*, *medium*, *large* et *whale*).




FIGURE 7. Caractéristiques des données utilisées pour la pool USDC/WETH 0.05%. À gauche : distribution du nombre de swaps observés par bloc Ethereum. Environ la moitié des blocs ne contient aucune transaction, quelques blocs concentrent un grand nombre d’échanges. À droite : distribution des volumes de transaction (en dollars). Les lignes verticales pointillées indiquent les seuils utilisés pour définir les cinq catégories de marques utilisées dans l’estimation du modèle.

Ce choix permet de distinguer l’influence des petites et des grandes transactions tout en conservant un nombre suffisant d’observations dans chaque catégorie.

4.3. Estimation des noyaux

4.3.1. Interactions entre achats et ventes

Nous étudions d’abord les interactions entre achats et ventes sur la pool USDC/USDT 0.01%, seule pool pour laquelle l’estimation conduit à une matrice de branchement vérifiant la condition de stabilité $\rho(\|\Phi\|) < 1$. Cette pool présente également l’avantage de correspondre à une paire de

stablecoins, dont la dynamique est généralement plus régulière que celle des pools exposées aux variations du prix de l’Ether ou du Bitcoin.

Les swaps sont séparés en deux processus correspondant respectivement aux achats et aux ventes. Les volumes sont discrétisés en cinq catégories de marques selon la procédure décrite précédemment.

La Figure 8 présente les noyaux et fonctions de marque estimés.




FIGURE 8. Estimation des interactions entre achats (1) et ventes (2) sur la pool USDC/USDT 0.01%. À gauche : noyaux agrégés. À droite : fonctions de marque.

Les noyaux présentent une décroissance rapide dans les premières secondes suivant un événement. Les interactions croisées entre achats et ventes demeurent de faible amplitude et deviennent rapidement proches de zéro.

Les fonctions de marque sont plus difficiles à interpréter. Certaines catégories de volume semblent contribuer davantage aux mécanismes d’excitation, mais les différences observées restent sensibles au bruit d’estimation, notamment pour les plus grandes marques.

Pour cette estimation, la matrice de branchement obtenue est

$$\|\Phi\| = \begin{pmatrix} 0.783 & 0.332 \\ -0.020 & 0.659 \end{pmatrix},$$

ce qui conduit à un rayon spectral $\rho(\|\Phi\|) = 0.72$. L’estimation est donc compatible avec l’hypothèse de stationnarité du modèle de Hawkes.

Les autres pools étudiées conduisent à des matrices de branchement dont le rayon spectral dépasse l’unité (Tableau 3). Les noyaux estimés présentent alors généralement des queues persistantes de faible amplitude qui contribuent fortement à leurs intégrales.

Ces résultats doivent être interprétés avec prudence. Ils peuvent traduire une violation des hypothèses de stationnarité du modèle sur les données réelles, mais également une difficulté d’estimation liée à la forte activité observée sur certaines pools. Nous ne les interprétons donc pas comme une preuve d’une dynamique réellement explosive, mais plutôt comme une limite de l’ajustement du modèle

TABLE 3. Rayon spectral des matrices de branchement estimées pour les différentes pools étudiées.

Pool	$\rho(\ \Phi\)$
USDC/WETH 0.05%	1.20
USDC/WETH 0.30%	3.20
WBTC/WETH 0.05%	1.90
WBTC/WETH 0.30%	2.10
USDC/USDT 0.01%	0.72

dans ce contexte.

Malgré cette limitation, les noyaux estimés présentent des structures qualitatives cohérentes entre pools, notamment des effets d’auto-excitation marqués sur les flux d’achats et de ventes. Il demeure donc intéressant d’examiner ces estimations à titre exploratoire. Nous présentons en particulier les résultats de la pool USDC/WETH 0.05%, qui concentre le plus grand nombre de transactions de l’échantillon.




FIGURE 9. Estimation des interactions entre achats (1) et ventes (2) sur la pool USDC/WETH 0.05%. À gauche : noyaux agrégés. À droite : fonctions de marque. Les courbes violettes représentent les estimations issues du modèle discret de Kirchner discuté dans les sous-sections 2.3 et 3.4.

Les fonctions de marque révèlent une différence nette entre interactions de même signe et interactions croisées. Les noyaux achat–achat et vente–vente sont principalement associés aux transactions de faible volume, tandis que les interactions achat–vente et vente–achat sont davantage portées par les transactions les plus importantes.

Les autres pools confirment partiellement cette observation. Dans les pools à faibles frais, les interactions de même signe restent principalement associées aux petites transactions, tandis que les interactions croisées sont davantage dominées par les grandes transactions.




FIGURE 10. Fonctions de marque estimées pour les interactions achat–vente sur les pools USDC/WETH 0.30%, WBTC/WETH 0.05% et WBTC/WETH 0.30% (de gauche à droite).

Cette distinction apparaît moins marquée lorsque les frais augmentent. Les fonctions de marque deviennent alors plus systématiquement croissantes avec le volume, y compris pour les interactions de même signe. Les différences observées suggèrent que le rôle relatif des petites et grandes transactions dépend de la structure de la pool et de son niveau de frais.

4.3.2. Interactions entre swaps, mint et burn

Nous avons également considéré un modèle distinguant les événements *swap*, *mint* et *burn* (cf. Figure 11). Contrairement au cas achat–vente, les noyaux estimés sont de faible amplitude et ne font pas apparaître de structure particulièrement nette. Les fonctions de marque sont également difficiles à interpréter et semblent fortement affectées par le bruit d’estimation.

Cette difficulté est probablement liée au faible nombre d’opérations *mint* et *burn* observées sur la période étudiée. Alors que les swaps représentent plusieurs centaines de milliers d’événements, seules quelques milliers d’opérations de fourniture et de retrait de liquidité sont disponibles. Les statistiques d’ordre deux associées à ces processus sont donc beaucoup plus bruitées, ce qui peut expliquer les noyaux de faible amplitude ainsi que les fonctions de marque peu informatives observées sur la Figure 11.

Une période d’observation plus longue permettrait d’augmenter le nombre de ces événements, mais au prix d’une hypothèse de stationnarité potentiellement moins réaliste.

5. Conclusion

Dans ce travail, nous avons étudié l’estimation non paramétrique de processus de Hawkes marqués à l’aide de l’approche Neural Hawkes proposée par FABRE et MUNI TOKE (2025). Après avoir présenté le cadre théorique fondé sur les statistiques d’ordre deux et l’équation de Wiener–Hopf, nous avons mis en œuvre cette méthode à l’aide d’un réseau de neurones de type Deep Galerkin Method.

Les expériences réalisées sur données simulées montrent que la méthode permet de reconstruire avec précision des noyaux de formes variées ainsi que la dépendance aux marques. Les erreurs observées sur les normes des noyaux et sur le rayon spectral demeurent faibles, ce qui confirme la capacité du




FIGURE 11. Estimation des interactions entre mint (1), burn (2) et swap (3) sur la pool USDC/WETH 0.05%. À gauche : noyaux agrégés. À droite : fonctions de marque.

modèle à retrouver les principales propriétés du processus générateur.

L'application à des données issues de plusieurs pools Uniswap V3 met en évidence des dépendances temporelles entre événements ainsi qu'un rôle important de la taille des transactions. Les fonctions de marque révèlent notamment des comportements différents selon le type d'interaction considéré et selon le niveau de frais des pools étudiées. Ces résultats suggèrent que l'information portée par le volume des transactions constitue un facteur essentiel de la dynamique des échanges décentralisés.

Cette étude met également en évidence plusieurs limites. Contrairement aux données simulées, la plupart des estimations réalisées sur données réelles conduisent à des rayons spectraux supérieurs à l'unité, ce qui suggère soit une violation des hypothèses de stationnarité du modèle, soit des difficultés d'estimation liées à la structure particulière des données blockchain. Les événements étant observés à l'échelle des blocs Ethereum, l'information temporelle disponible reste plus limitée que sur les marchés centralisés traditionnels. Par ailleurs, certains types d'événements, notamment les opérations de fourniture et de retrait de liquidité, restent peu fréquents, ce qui complique l'estimation de leurs interactions.

Enfin, nous avons comparé l'approche retenue à un modèle discret de type INAR proposé par KIRCHNER (2016). Les résultats obtenus sur données simulées montrent que la redistribution uniforme des événements à l'intérieur des blocs préserve correctement les principales dépendances temporelles du processus. Néanmoins, le modèle de Kirchner apparaît comme une alternative particulièrement naturelle dans le contexte blockchain, puisqu'il exploite directement les comptages observés par bloc sans nécessiter de reconstruction temporelle.

Les résultats obtenus montrent ainsi que les processus de Hawkes constituent un outil pertinent pour l'étude de la microstructure des marchés décentralisés, tout en soulignant la nécessité d'adapter ces modèles aux spécificités des données blockchain. Parmi les prolongements possibles figurent l'étude de modèles non stationnaires, l'utilisation de périodes d'observation plus longues ainsi que le développement de modèles discrets permettant de conserver l'information portée par les marques.

Bibliographie

- BACRY, Emmanuel et Jean-François MUZY (2016). “Second Order Statistics Characterization of Hawkes Processes and Non-Parametric Estimation”. In : *IEEE Transactions on Information Theory* 62.4, p. 2184-2202.
- DI NOSSE, Daniele Maria et al. (2025). “Deviations from Tradition : Stylized Facts in the Era of DeFi”. In : *arXiv preprint arXiv :2510.22834*. arXiv : [2510.22834](https://arxiv.org/abs/2510.22834) [q-fin.TR].
- FABRE, Timothee et Ioane MUNI TOKE (2025). “Neural Hawkes : non-parametric estimation in high dimension and causality analysis in cryptocurrency markets”. In : *Quantitative Finance* 25.5, p. 671-698.
- HAWKES, Alan G. et David OAKES (1974). “A Cluster Process Representation of a Self-Exciting Process”. In : *Journal of Applied Probability* 11.3, p. 493-503.
- KIRCHNER, Matthias (2016). “Hawkes and INAR(∞) Processes”. In : *Stochastic Processes and their Applications* 126.8, p. 2494-2525.