

# Estimation non paramétrique de processus de Hawkes sur données Uniswap V3

Adrien Damez, Ilyas El-Tabouti, Majd Sebbah, Housseem Elhamdi, Abdellah Taybi

## Contexte et objectif

Les processus de Hawkes constituent un cadre classique pour modéliser les dépendances temporelles entre événements financiers. Ils sont notamment utilisés en microstructure des marchés pour quantifier des phénomènes d'auto-excitation : l'occurrence d'une transaction peut augmenter temporairement la probabilité d'apparition de transactions futures.

La majorité des applications financières concernent cependant les marchés centralisés reposant sur un carnet d'ordres. Les échanges décentralisés (*Decentralized Exchanges*, DEX) tels qu'Uniswap fonctionnent selon une structure différente : les transactions sont exécutées contre les réserves de liquidité d'une pool via un mécanisme d'*Automated Market Maker* (AMM). Les événements observés sont donc de nature différente : échanges (*swaps*), ajouts de liquidité (*mint*) et retraits de liquidité (*burn*). De plus, les données Ethereum sont regroupées par blocs, ce qui introduit des simultanités artificielles absentes des données de marché classiques.

L'objectif de ce projet est d'étudier l'estimation non paramétrique de processus de Hawkes dans ce contexte. Nous nous appuyons principalement sur la méthode *Neural Hawkes* proposée par FABRE et MUNI TOKE (2025), tout en la comparant à une approche discrète de type INAR proposée par KIRCHNER (2016). Cette comparaison est naturelle : Neural Hawkes fournit une estimation continue et marquée des noyaux, tandis que le modèle de Kirchner travaille directement sur des comptages par blocs.

## Méthodologie

Les processus de Hawkes permettent de modéliser des phénomènes d'auto-excitation entre événements. Dans le cas multivarié, l'intensité conditionnelle du processus s'écrit

$$\lambda_i(t) = \mu_i + \sum_{j=1}^D \sum_{t_k^j < t} \phi_{ij}(t - t_k^j, m_k^j),$$

où  $\mu_i$  est l'intensité de base du processus et où les noyaux  $\phi_{ij}$  décrivent l'influence d'un événement passé de type  $j$  sur l'intensité future du processus  $i$ .

Un résultat de BACRY et MUZY (2016) montre que ces noyaux sont entièrement caractérisés par certaines statistiques d'ordre deux du processus. Pour un événement de type  $j$  observé à l'instant 0, on considère la fonction  $G_{ij}(t, m)$ , qui mesure l'excès moyen d'activité du processus  $i$  observé un temps  $t$  plus tard. Cette quantité peut être estimée directement à partir des données en moyennant les événements observés après chaque occurrence de type  $j$ . Les fonctions  $G_{ij}$  vérifient alors l'équation de Wiener-Hopf

$$G = \Phi + \Phi * G.$$

La méthode Neural Hawkes proposée par FABRE et MUNI TOKE (2025) consiste à remplacer la résolution matricielle de l'équation de Wiener-Hopf par un problème d'apprentissage. Les paramètres d'un réseau de neurones sont ajustés de manière à minimiser l'écart entre les statistiques d'ordre deux observées et celles reconstruites par le modèle. Cette approche évite l'inversion directe de grands systèmes linéaires et présente de meilleures propriétés de stabilité numérique dans les problèmes de grande dimension.

Nous comparons cette approche au modèle discret proposé par KIRCHNER (2016), plus directement adapté aux données blockchain. Pour un pas de temps  $\Delta$ , il modélise les comptages observés dans chaque bloc selon


$$\lambda_t = \mu + \sum_{k=1}^K A_k N_{t-k},$$

où les matrices  $A_k$  jouent un rôle analogue aux noyaux d'un processus de Hawkes. Lorsque  $\Delta \rightarrow 0$ , ce modèle converge vers un processus de Hawkes convenablement paramétré, établissant ainsi un lien théorique entre les approches discrète et continue.

## Validation sur données simulées

Avant l'application aux données réelles, les méthodes sont testées sur des données simulées dont les noyaux sont connus. Afin de reproduire les caractéristiques des données Ethereum, les événements simulés sont ensuite agrégés en blocs. Le pas de discrétisation est choisi de manière à obtenir des statistiques proches de celles observées sur les données réelles, avec environ un événement par bloc en moyenne et près de 50% de blocs vides.

Pour appliquer Neural Hawkes à ces données agrégées, les événements contenus dans un même bloc sont ensuite redistribués uniformément à l'intérieur de celui-ci tout en conservant leur ordre d'apparition. Le modèle de Kirchner est quant à lui appliqué directement aux comptages observés par bloc



**FIGURE 1** – Comparaison entre les noyaux théoriques agrégés, l'estimation Neural Hawkes après reconstruction temporelle et l'estimation discrète de Kirchner (gauche). À droite, comparaison entre les fonctions de marque théoriques et celles estimées par Neural Hawkes.

La Figure 1 montre que les deux approches retrouvent les principales structures temporelles malgré cette agrégation. Neural Hawkes reste proche du noyau théorique après reconstruction temporelle des événements, tandis que le modèle de Kirchner fournit une estimation cohérente directement à partir des comptages observés. Les fonctions de marque sont également correctement reconstruites par Neural Hawkes. Ces résultats suggèrent que la reconstruction temporelle utilisée pour appliquer le modèle continu aux données blockchain préserve l'essentiel de l'information contenue dans le processus simulé.


## Application aux données Uniswap V3

Les données étudiées proviennent de cinq pools Uniswap V3 sur Ethereum Mainnet, observées entre le 18 janvier et le 16 février 2026. La pool USDC/WETH 0.05% est la plus active de l'échantillon, avec 230 249 swaps. Les pools à faibles frais concentrent généralement davantage d'activité que leurs équivalents à 0.30%.

Nous nous concentrons principalement sur les interactions entre achats et ventes. Les swaps sont séparés en deux processus, et la taille des transactions est utilisée comme marque. La Figure 2 présente les résultats pour la pool USDC/WETH 0.05%.

Les deux méthodes mettent en évidence une forte auto-excitation des flux d'achats et de ventes à court horizon. Les interactions croisées sont plus sensibles au choix du modèle.

Les fonctions de marque suggèrent que la taille des transactions joue un rôle important. Sur les pools à faibles frais, les interactions de même signe sont principalement associées aux petites transactions, tandis que les interactions croisées sont davantage portées par les transactions les plus importantes. Ce résultat reste exploratoire, car les plus



**FIGURE 2** – Estimation des interactions entre achats (1) et ventes (2) sur la pool USDC/WETH 0.05%. À gauche : noyaux agrégés. À droite : fonctions de marque. Les courbes violettes représentent les estimations issues du modèle discret de Kirchner.

grandes marques sont moins fréquentes et donc plus bruitées.

Nous avons également étudié un modèle distinguant les événements *swap*, *mint* et *burn*. Les noyaux obtenus sont cependant de faible amplitude et difficiles à interpréter. Cette limite semble liée au faible nombre d’opérations de liquidité relativement au nombre de swaps : les statistiques d’ordre deux associées aux *mint* et *burn* sont donc beaucoup plus bruitées.

## Conclusion

Ce projet a permis d’étudier l’estimation non paramétrique de processus de Hawkes marqués dans un contexte de finance décentralisée. Les simulations montrent que Neural Hawkes et le modèle discret de Kirchner reconstruisent correctement les dépendances temporelles principales, même après agrégation en blocs.

L’application aux données Uniswap V3 met en évidence des phénomènes d’auto-excitation sur les flux d’achats et de ventes ainsi qu’une influence notable du volume des transactions. Elle révèle aussi les limites du cadre continu sur données blockchain : les événements sont observés par blocs, les hypothèses de stationnarité sont discutables, et certains types d’événements restent trop rares pour être estimés de manière robuste.

Le modèle de Kirchner apparaît donc comme une alternative naturelle dans ce contexte, tandis que Neural Hawkes conserve l’avantage d’intégrer directement les marques et de fournir une estimation continue des noyaux.

## Références

- BACRY, Emmanuel et Jean-François MUZY (2016). “Second Order Statistics Characterization of Hawkes Processes and Non-Parametric Estimation”. In : *IEEE Transactions on Information Theory* 62.4, p. 2184-2202.
- FABRE, Timothee et Ioane MUNI TOKE (2025). “Neural Hawkes : non-parametric estimation in high dimension and causality analysis in cryptocurrency markets”. In : *Quantitative Finance* 25.5, p. 671-698.
- KIRCHNER, Matthias (2016). “Hawkes and INAR( $\infty$ ) Processes”. In : *Stochastic Processes and their Applications* 126.8, p. 2494-2525.